PROYECTO FINAL

Entrega de Datos y Preparación

De la idea de producto a unos datos reales, trazables y utilizables

RaceEstrategy

Documentación de Datos Actualizada

Índice de Contenidos

1. Qué datos necesita vuestro producto

2. Fuentes reales y viabilidad (Datos propios + FitRec masivo)

3. Uso, privacidad y datos personales

4. Del dato bruto al dato utilizable (Flujo Bronze → Silver → Gold)

5. Riesgos y limitaciones (Resolución del balanceo multideporte)

A. Anexo – Muestras de Datasets Gold (Ciclismo y Running)

---

1. Qué datos necesita vuestro producto

En la capa final (Gold), cada fila representa **una actividad deportiva individual completada por un deportista** (o un tramo/segmento homogéneo de ruta).

1.1 Datos imprescindibles

• `deporte` / `sub_deporte` / `modalidad`: Identificador de la disciplina (ciclismo de carretera / bicicleta, MTB, carrera a pie / running, caminata).

• `distancia_km`: Longitud total del recorrido en kilómetros.

• `desnivel_positivo_m` y `ratio_subida_m_km`: Metros de ascenso acumulado y ratio de pendiente media.

• `duracion_segundos` / `duracion_min` / `velocidad_media_kmh`: Variable objetivo para los futuros modelos de Machine Learning (predecir tiempo estimado o ritmo sostenible).

• `id_atleta` / `usuario` (seudonimizado): Imprescindible para controlar el sesgo por usuario y evitar data leakage entre entrenamiento y test.

1.2 Datos deseables

Frecuencia cardíaca media y serie temporal de pulso, potencia (vatios), cadencia y temperatura ambiente (disponibles en dispositivos avanzados y en el dataset FitRec).

1.3 Granularidad e histórico

Granularidad a nivel de actividad completa (agregada) para modelos macro de predicción de tiempo, con capacidad de descender a granularidad segundo a segundo (series temporales GPS, FC y altimetría) para perfiles de altitud, pendientes por tramos y análisis de esfuerzo.

2. Fuentes reales y viabilidad

2.1 Fuentes utilizadas e integradas

#	Fuente	Formato	Volumen	Detalles y Características
1	Datos de campo Garmin (Outdoor)	.fit	529 archivos	Garmin Edge Explore 20 y Edge 830. Cobertura multianual, altimetría barométrica, 1 s muestreo.
2	Entrenamientos Indoor	.fit	81 archivos	Actividades indoor/rodillo sin GPS con métricas de pulso, tiempo y cadencia/potencia.
3	Exportación de Strava	.gpx	434 actividades	Móvil y GPS con etiquetado manual de usuario y perfiles de ruta.
4	Dataset FitRec (Endomondo)	.json / .csv	229.413 acts (1.090 usuarios)	Dataset masivo: 117.902 carreras, 98.001 ciclismo en ruta y 13.510 MTB con 100% de FC y altitud.
5	Fuentes abiertas base	Vectorial	Referencia	Catálogo CNIG/IMBA para validación de perfiles topográficos.

2.2 Viabilidad y estabilidad

• El acceso a los archivos locales (.fit, .gpx, extractos procesados de FitRec) es 100% autónomo y offline.

• **Alternativa de contingencia:** Si faltase telemetría barométrica en un archivo GPX, la altitud se puede imputar cruzando coordenadas con un DEM abierto (SRTM o Copernicus EU-DEM).

3. Uso, privacidad y datos personales

3.1 Diagnóstico de privacidad en los datos brutos

• Los archivos `.fit` de fábrica contenían metadatos sensibles: números de serie de dispositivos Garmin (`serial_number`), edad, peso corporal exacto y nombres de perfil.

• Los archivos `.gpx` de Strava contenían en el nombre el identificador público de la actividad.

• El dataset FitRec contiene identificadores numéricos de usuario (`userId`) y género.

3.2 Medidas de minimización y RGPD aplicadas

Medida de Protección	Descripción y Aplicación Técnica
Anonimización irreversible	Eliminación de identificadores directos. Los seriales y usuarios se mapean a hashes seguros tipo atleta_a1b2c3.
Disociación antropométrica	Peso y edad desacoplados de la tabla de entrenamiento principal para evitar reidentificación.
Protección residencial	En producción se aplica máscara/recorte de los primeros y últimos 500 metros para no revelar la ubicación del domicilio.
Buenas prácticas Git	No se sube el dataset gigante completo a Git (se gestiona vía .gitignore y scripts reproducibles), versionando código ETL/EDA e informes.

4. Del dato bruto al dato utilizable

Flujo Bronze → Silver → Gold

```
[Bronze / Raw]                  [Silver / Cleaned]                  [Gold / ML-Ready]
Archivos brutos y datasets      Limpieza, tipos y auditoria         Datasets listos para ML
• 963 tracks (.fit y .gpx)      • Filtro duracion (<2 min, >24h)    • gold_ciclismo.csv (934 base)
• 81 fit indoor sin GPS         • Descarte anomalias velocidad      • gold_running.csv (17 base)
• 229.413 acts FitRec    -->    • Saltos GPS (>2 km) y altitud -->  • FitRec ML-Ready (>229.000 acts:
  (117.9k run, 98.0k bike,      • Estandarizacion unidades (SI)       117.8k running, 97.8k ciclismo,
   13.5k MTB)                   • Auditoria series temporales         13.5k MTB)
```

4.1 Capa Bronze / Raw (Adquisición)

- Datos locales: 963 archivos de actividades de campo (434 .gpx y 529 .fit) más 81 .fit indoor.
- Dataset externo integrado: 229.413 registros filtrados por modalidades objetivo (run, bike, mountain bike) a partir de endomondoHR.json.
- Se conservan los datos originales sin alteraciones destructivas para trazabilidad completa.

4.2 Capa Silver (Limpieza, Calidad y Homogeneización)

Transformación	Criterio y Detalle de Limpieza
Filtro de integridad y ruido	Descarte de actividades con duración < 2 min o distancia < 200 m, así como duraciones irreales (>24 horas).
Control de anomalías físicas y GPS	Detección y filtrado de saltos GPS > 2 km entre puntos consecutivos (1.635 casos auditados), saltos bruscos de altitud (>100 m) y velocidades medias no plausibles (>100 km/h ciclismo, >35 km/h running).
Estandarización de unidades	Conversión al SI: distancia_km, duracion_min, duracion_segundos, desnivel_positivo_m, velocidad_media_kmh.
Resultado Silver	Local: 951 actividades limpias en silver_actividades.csv. FitRec: 229.190 candidatas válidas (99,9% aptas).

4.3 Capa Gold (Consumo para Machine Learning)

Dataset	Filas	Columnas clave	Uso previsto
gold_ciclismo.csv (Local)	934	distancia_km, desnivel_positivo_m, ratio_subida_m_km, vel_media, duracion_s	Modelado de ciclismo con alta precisión barométrica.
gold_running_caminata.csv (Local)	17	Estructura análoga para actividades a pie	Muestras de campo locales a pie.
FitRec Ciclismo en Ruta	97.865	usuario, distancia_km, duracion_min, vel_media, series FC/altitud	Modelos generalizables y validación cruzada por usuario.
FitRec Carrera (Running)	117.819	usuario, distancia_km, duracion_min, vel_media, series FC/altitud	Entrenamiento robusto de carrera (resolución del desbalanceo).
FitRec MTB	13.506	usuario, distancia_km, duracion_min, vel_media, series FC/altitud	Modelado específico para ciclismo de montaña.

5. Riesgos y limitaciones

#	Riesgo / Limitación	Descripción y Plan de Mitigación
1	Desbalanceo entre disciplinas	Completamente resuelto con la integración del dataset FitRec (117.819 carreras de 698 usuarios recurrentes frente a las 17 locales iniciales).
2	Métricas fisiológicas completas	Las actividades locales carecían de pulso en algunos tramos. FitRec aporta un 100% de cobertura en series temporales de frecuencia cardíaca.
3	Calidad y ruido en señales GPS	Auditadas y aisladas anomalías (1.635 saltos GPS > 2 km y tramos dudosos) mediante pipelines reproducibles (eda_calidad_fitrec.py).
4	Plan de contingencia	Flujo Bronze → Silver → Gold totalmente automatizado y reproducible en Python.

Anexo A. Muestra de Datos – Gold Ciclismo

id_actividad	id_atleta	dist_km	desnivel_m	vel_media	duracion_s
10357134622	atleta_881e32	26.08	317.0	20.54	4 571
10384116339	atleta_49d4b3	64.10	627.7	16.93	13 634
10388805888	atleta_acbbda	63.78	405.8	14.78	15 533
10418992434	atleta_587306	43.53	496.8	20.16	7 773

Anexo B. Muestra de Datos – Gold Running / Caminata

id_actividad	id_atleta	dist_km	desnivel_m	vel_media	duracion_s
5096704595	atleta_68fdcd	5.05	90.5	6.87	2 645
5737302697	atleta_3eb79d	10.85	45.0	4.57	8 553
6132712537	atleta_8b5fbb	4.33	64.5	7.23	2 155
6137698933	atleta_8b04a1	5.34	61.5	7.03	2 736